

# Introduction to R

Zoltan Kekecs, Marton Kovacs

February 11, 2020

## Contents

<b>1</b>	<b>Bevezetés az R programnyelvbe</b>	<b>2</b>
1.1	Absztrakt . . . . .	2
<b>2</b>	<b>Bevezetés az R programozásba</b>	<b>2</b>
<b>3</b>	<b>Konzol</b>	<b>2</b>
<b>4</b>	<b>Script</b>	<b>2</b>
<b>5</b>	<b>Befejezett és befejezetlen parancsok</b>	<b>3</b>
<b>6</b>	<b>Funkciók</b>	<b>3</b>
<b>7</b>	<b>Objektumok</b>	<b>4</b>
<b>8</b>	<b>Munkaterület (workspace, environment)</b>	<b>4</b>
<b>9</b>	<b>Csomagok (Packages)</b>	<b>4</b>
9.1	Package installálása . . . . .	5
9.2	Package betöltése . . . . .	5
<b>10</b>	<b>Objektum típusok</b>	<b>6</b>
10.1	Adattípusok . . . . .	6
10.2	Objektumok osztályozása (object class) . . . . .	6
<b>11</b>	<b>Néhány hasznos rövidítés:</b>	<b>7</b>

# 1 Bevezetés az R programnyelvbe

## 1.1 Absztrakt

Ez a gyakorlat egy bevezető az R program alkalmazásába. A gyakorlat bemutatja az R legalapvetőbb funkcióit, a konzol és a script használatát. Bemutatja a különböző adatfajtákat, mint pl. a vektor, a mátrix és az adattábla, és megismertet néhány alapvető adatkezelési művelettel.

## 2 Bevezetés az R programozásba

Az R egy programozási nyelv. Ha az R programnyelv kifejezéseit kell használnunk ahhoz, hogy használjuk a programot.

Például az R ismeri a matematika alapvető kifejezéseit.

```
21 + 16
```

```
## [1] 37
```

```
3 * 5
```

```
## [1] 15
```

```
10 * 2 / 5 + 2
```

```
## [1] 6
```

## 3 Konzol

Az R programozás során mondatokat használunk, hasonlóképpen ahhoz mintha emberekkel kommunikálnánk írásban. Az R-nek szánt parancsokat (mondatokat) beírhatjuk egyenesen a konzolba (ez általában a bal alsó panel szokott lenni az RStúdióban, amin az a felirat szerepel hogy “Console”).

Próbáld ki most ezt, írd be egy matematikai műveletet közvetlenül a konzolba a fenti kódhoz hasonlóan, és nyomd meg az ENTER-t (pl.  $12/3$ , egyenlőség jelet nem kell tenni).

Az R lefuttatja a kért műveletet, és a konzolban megjeleníti az eredményt közvetlenül a lefuttatott parancs sora után. Vedd észre hogy a lefuttatott parancsot tartalmazó sor elején mindig egy “>” jel van. Az eredmény sor elején pedig a következővel kezdődik: “[1]” Ezeket a jeleket nem kell értelmeznünk.

## 4 Script

Bár megtehetnénk, hogy mindent közvetlenül a konzolba írunk, így nagyon nehezen lehetne reprodukálni amit csináltunk, mert a konzolban a kód egy idő után kitörlődik, és különben is nehezen átlátható a konzol néhány parancs után. Ehelyett a kódunkat általában egy szöveges fájlba mentjük, ezt gyakran “script”-nek hívják, mert olyan mint egy forgatókönyv. Ezt a script-et előre megírjuk, és ez alapján a forgatókönyv alapján fogja teljesíteni az R a parancsokat, amikor szeretnénk azokat lefuttatni.

A script általában a bal felső panel az RStudio-ban. Néha először csak a konzolt látjuk. Ilyenkore a File menüben a New file > R Script kiválasztásával tudunk egy script panelt nyitni. Most tedd ezt meg, és írd a script panelba néhány matematikai műveletet enterrel elválasztva. Pl.:

```
2 * 4
```

```
10 / 5
```

Láthatod, hogy amikor itt enter-t nyomsz, a kód nem fut le, nincs eredmény. Ez jó így, itt előre megírhatjuk a kódot, és addig nem fut le, amíg mi erre utasítást nem adunk.

Most adjunk utasítást a kód lefuttatására. Ezt több módon is megtehetjük. A legegyszerűbb módja, ha az egérrel kijelöljük a kódot amit szeretnénk lefuttatni, és megnyomjuk a Ctrl+ENTER billentyűket egyszerre. Ekkor a kijelölt kódrész lefut a konzolban, mintha egyenesen oda írtuk volna be.

Ennél méggyorsabb megoldás, ha a lefuttatni kívánt kód sorába kattintunk az egérrel, és megnyomjuk a Ctrl+ENTER-t. Ekkor az a sor ahol a kurzor volt lefut, és a kurzor átugrik a következő sor elejére.

Próbáld most ki a következőt: Írj be 3 matematikai műveletet egymás alá új sorokba a scriptedbe (az ENTER segítségével tudsz új sort kezdeni). Majd vidd a kurzort a legelső sorba (nem kell semmit kijelölni, csak bizonyosodj meg róla hogy a kurzor valahol a megfelelő sorban van), és nyomd meg a Ctrl+ENTER billentyűket többször egymás után. Azt kell tapasztalnod, hogy a parancsok soronként lefutnak az R-ben.

## 5 Befejezett és befejezetlen parancsok

Most próbáld meg lefuttatni a következő parancs-részletet:

```
9 / 3 + 6 *
```

Vedd észre hogy ez egy parancs-töredék, nincs befejezve, mert az R vár még valamit a “mondat” végére (tudnia kell, mivel kell megszorozni a 6-ot). Amikor a konzolban megpróbáljuk ezt lefuttatni, vedd észre hogy a szokásos “>” vagy “[1]” helyett egy “+” jel szerepel a sor elején! Ez azt jelenti, hogy az R vár még valamit a parancs befejezéséhez, hogy parancs-töredéket futtattunk le. Az R tanulása közben előfordul, azt vesszük észre, hogy az R “nem teljesíti a parancsokat”, nem ad ki eredményt. Ez általában amiatt van hogy egy kódsoroknak véletlenül csak töredékét futtatjuk le, és emiatt valamit befejezetlenül hagyunk, és az R várja, hogy “befejezzük a mondatot”. Ezt a legkönnyebben úgy vehetjük észre, hogy az R konzolban “+” jelet látunk a sor elején.

A fenti példában tudjuk hogy mi a kódtöredék, és tudjuk, mivel lehet befejezni a kódot, egy számmal. Szóval írj egy számot a konzolba és nyomd meg az ENTER-t. Ezzel befejeződik a kód és a konzolban láthatjuk a művelet eredményét. Azonban gyakran amikor a konzolban “+” jelet látunk, nehéz visszafejteni, hogy mi az a mondatbefejezés amire az R vár, mert nem tudjuk, hol rontottuk el a kódot. Ilyenkor a legegyszerűbb, ha egy vagy néha több zárójelet ) -et írunk a konzolba és megnyomjuk az ENTER-t. Ekkor általában egy hibaüzenetet kapunk, vagyis a kódunk nem fut le, de legalább újra az ismerős “>” jel fogad minket, ami azt mutatja, hogy az R készen áll új parancsra. Szóval ha valamikor megakadtok és úgy tűnik az R nem válaszol, ellenőrizzétek hogy “>” jel van-e a konzolban. Ha “>” jel helyett “+”-t találtok, akkor zárjátok le a mondatot, ha kell a ) használatával. Ha nem vagytok benne biztosak, meddig futott le a kódotok, sokszor érdemes a script-et újra a legelejétől lefuttatni. Sőt, néha a programot is érdemes újraindítani ez előtt, vagy legalább a “munkaterületet” (Workspace) kitisztítani a korábbi fennmaradó kódoktól, objektumoktól.

## 6 Funkciók

Az R-ben a különböző műveleteket legtöbbször funkciók segítségével végezzük el. Ezek az R programnyelv “igéi”.

Például egy szám 10-es alapú logaritmuást a log() funcióval tudhatjuk meg.

```
log(2)
```

```
## [1] 0.6931472
```

Rengeteg funkcióval fogunk megismerkedni a kurzus során.

Magunk is csinálhatunk funkciót (erre számos tananyagot találhatsz az interneten), de a legtöbb funkció ami ehhez a bevezetés kurzushoz kell már megtalálható az R-ben.

## 7 Objektumok

Ha a funckiók az R programnyelv igéi, akkor az objektumok a főnevek. Az objektumok általában olyan adatok amiknek valami nevet adtunk, hogy később könnyebben elérhessük, hivatkozhatunk rá.

pl. az alábbi kóddal hozzárendelhetjük a “Tesla model S” szöveget a dreamcar objektumhoz.

```
dreamcar <- "Tesla model S"
```

Innentől kezdve mindig amikor előhívjuk ezt a dreamcar objektumot, akkor az R tudja hogy a “Tesla model S”-re hivatkozunk.

Az objektum lefuttatásával az R a konzolban kilistázza a benne foglalt elemeket.

```
dreamcar
```

```
## [1] "Tesla model S"
```

A “<-” és a “=” felcserélhető. Ugyan azt csinálja.

```
dreamcar = "Tesla model S"
```

Az objektumokkal ugyan úgy tudunk műveleteket végezni, mint azok tartalmával. Pl.:

```
number1 <- 5
```

```
number2 <- 2
```

```
sum_total = number1 + number2
```

```
sum_total
```

```
## [1] 7
```

---

### Gyakorlás

1. Rendeld hozzá a 4-et egy új *number* nevű objektumhoz.
2. vond ki a *number1* és a *number2* összegéből ezt az objektumot, és az eredményt rendeld hozzá egy *result* nevű objektumhoz.
3. listázd ki a *result* objektumot hogy leellenőrizd, helyes eredményt kaptál-e

---

## 8 Munkaterület (workspace, environment)

Az RStúdióban jobb felül található általában a munkakörnyezet (Environment), ami tartalmazza az éppen aktuálisan használt adatokat, objektumokat, egyéb nevesített értékeket. Az itt található kis seprű ikon megnyomásával kitisztíthatjuk a “munkaterületet” (Workspace) a korábbi fennmaradó objektumoktól. Ezt érdemes megtenni ha újra kaarjuk futtatni a kódunkat.

## 9 Csomagok (Packages)

Az R egyik előnye hogy a közösség folyamatosan fejlődik. ezt úgy érik el, hogy az R rendelkezik néhány nagyon stabil és standardizált alapfunkcióval, amire mások ráépíthetik saját kódjaikat. Amikor ezek a saját kódok és funckiók egy hasznos egységgé állnak össze, ezeket úgynevezett funckió “csomag” (package)-ként adják ki a programozók. Ezek a package-ek nagyon megnövelik az R funkcionalitását és felhasználóbarátságát.

Számunkra a legalapvetőbb csomag amit használni fogunk a “tidyverse”. Ez valójában egy csomag-család, ami tiszta, olvasható programozást tesz lehetővé.

A jobb alsó panel az RStúdióban általában tartalmaz egy Packages tab-ot. Erre kattintva megláthatjuk hogy mik a telepített package-ek, és hogy ezek közül melyik van betöltve (amik mellett pipa van).

## 9.1 Package installálása

A következő parancs arra szolgál, hogy egy google spreadsheet-ből olvassunk be adatot, viszont jelenleg hibaüzenetet ad ki.

```
url = gs_url("https://docs.google.com/spreadsheets/d/1uYMBbvdJVOAs1bDWE0821xXaCzRAZ_oyAYTdUa_gEqA/edit?")
```

Ez azért van mert nincs benne az R alapsomagjában (amit R base-nek is szoktak nevezni), hanem egy package, a googlesheets, installálása és betöltése kell hozzá.

Package-eket installálhatunk a konzolból, vagy script-ből a következő kód lefuttatásával: `install.packages()`. A zárójelbe a package nevét idézőjelben kell betenni.

Pl.:

```
install.packages("googlesheets")
```

## 9.2 Package betöltése

Fontos, hogy nem elég egy package-et installálni, ha a tartalmát használni akarjuk. A package-et be is kell töltenünk. Ezt a `library()` funkcióval tudjuk megtenni (itt már nincs szükség az idézőjelre a package neve körül).

```
library(googlesheets)
```

Most már le fog futni a parancs amit az előbb futtatni akartunk, és meg is nézhetjük az adatokat a `View()` funkcióval.

```
url = gs_url("https://docs.google.com/spreadsheets/d/1uYMBbvdJVOAs1bDWE0821xXaCzRAZ_oyAYTdUa_gEqA/edit?")
```

```
## Sheet-identifying info appears to be a browser URL.
```

```
## googlesheets will attempt to extract sheet key from the URL.
```

```
## Putative key: 1uYMBbvdJVOAs1bDWE0821xXaCzRAZ_oyAYTdUa_gEqA
```

```
## Worksheets feed constructed with public visibility
```

```
data = gs_read(url)
```

```
## Accessing worksheet titled 'ora_1'.
```

```
## Parsed with column specification:
```

```
## cols(
```

```
##   .default = col_double(),
```

```
##   Timestamp = col_character(),
```

```
##   Nem = col_character(),
```

```
##   Életkor = col_character(),
```

```
##   `Mi a legfőbb oka az elégtelen alvásnak, amikor nem alszol eleget?` = col_character(),
```

```
##   `1. rontott szám, helyette mondott szám` = col_character(),
```

```
##   `2. rontott szám, helyette mondott szám` = col_character(),
```

```
##   `3. rontott szám, helyette mondott szám` = col_character(),
```

```
##   `4. rontott szám, helyette mondott szám` = col_character(),
```

```
##   `5. rontott szám, helyette mondott szám` = col_character(),
```

```
##   `6. rontott szám, helyette mondott szám` = col_character(),
```

```
##   `A teremben vagy a termen kívül csináltad a memória-felmérést?` = col_character()
```

```
## )
```

```
## See spec(...) for full column specifications.
```

```
View(data)
```

## 10 Objektum típusok

### 10.1 Adattípusok

Az R többféle adattípust különböztet meg.

character numeric integer logical complex

```
x_character <- "I love R" # character
x_numeric <- 2.34 # numeric
x_integer <- 2L # integer
x_logical <- TRUE # logical
x_complex <- 1+4i # complex
```

Egy objektumban több adat is szerepelhet, vagyis az adatok adatstruktúrákat alkotnak. Amikor egy objektumban csak egy elem szerepel, azt “atomic vector”-nak, elemi vektornak nevezzük. (Mint a fenti példában x).

A `c()` függvényel viszont összefűzhetünk több (ugyan olyan típusú) adatot egy vektorrá.

```
numbers <- c(5, 2, 3, 24, 6, 5, 9, 10)
```

```
numbers
```

```
## [1] 5 2 3 24 6 5 9 10
```

### 10.2 Objektumok osztályozása (object class)

A *matrix*, amiben a vektorok egy táblázatot alkotnak. A mátrixban minden vektor/adat típusa csak ugyan az lehet.

```
my_matrix <- matrix(numbers, nrow = 2)
```

```
my_matrix
```

```
##      [,1] [,2] [,3] [,4]
## [1,] 5    3    6    9
## [2,] 2   24    5   10
```

Az adattábla (data frame), ami egy olyan mátrix, aminben oszloponként megengedett hogy különbözzön az adat típusa.

```
my_dataframe <- data.frame(my_matrix)
```

```
my_dataframe
```

```
##   X1 X2 X3 X4
## 1  5  3  6  9
## 2  2 24  5 10
```

És a lista, ami gyakorlatilag egy olyan vektor, aminek az elemei lehetnek más objektumok, vagy akár más listák.

```
my_list <- list(my_dataframe, numbers, x_character)
```

```
my_list
```

```
## [[1]]
##   X1 X2 X3 X4
## 1  5  3  6  9
```

```
## 2 2 24 5 10
##
## [[2]]
## [1] 5 2 3 24 6 5 9 10
##
## [[3]]
## [1] "I love R"
```

A következő funckiókkal különböző információkat tudhatunk meg az objektumokról: `class()` - what kind of object is it (high-level)? `typeof()` - what is the object's data type (low-level)? `length()` - how long is it? What about two dimensional objects? `attributes()` - does it have any metadata?

```
class(my_dataframe)
```

```
## [1] "data.frame"
```

```
typeof(my_dataframe)
```

```
## [1] "list"
```

```
length(numbers)
```

```
## [1] 8
```

```
attributes(my_matrix)
```

```
## $dim
```

```
## [1] 2 4
```

## 11 Néhány hasznos rövidítés:

Ha két szám közé kettőspontot teszünk, akkor az R azt egy számsorozatként értelmezi, aminek az első eleme a kettőspont előtti szám, egyesével növekszik, és a kettőspont utáni szám az utolsó eleme. Vagyis ha monoton egyesével növekvő számsort akarunk beírni, akkor ezt könnyedén lerövidíthetjük alábbi módon

```
1:5 # numbers from 1 to 5
```

```
## [1] 1 2 3 4 5
```

Az R-ben szintén megtalálható az angol ABC betűi. Az angol ABC kisbetűi a `letters` objektumban vannak benne, a nagybetűk pedig a `LETTERS` objektumban. A fenti trükkel tehát elérhetjük.

```
letters # lists the English alphabet letters
```

```
## [1] "a" "b" "c" "d" "e" "f" "g" "h" "i" "j" "k" "l" "m" "n" "o" "p" "q" "r" "s"
```

```
## [20] "t" "u" "v" "w" "x" "y" "z"
```

Ha egy vektornak csak bizonyos elemeit szeretnénk használni, akkor a `[]` és egy szám segítségével megmondhatjuk, melyik részét szeretnénk használni a vektornak. Vagyis a fenti két trükk kombinációjával nagyon rövid kóddal kikistáztathatjuk az angol ABC első 22 betűjét:

```
letters[1:22] # first 22 letters of the English alphabet
```

```
## [1] "a" "b" "c" "d" "e" "f" "g" "h" "i" "j" "k" "l" "m" "n" "o" "p" "q" "r" "s"
```

```
## [20] "t" "u" "v"
```