

# Kevert modellek - alapok

*Zoltan Kekecs*

*18 november 2019*

## Contents

<b>1</b>	<b>Absztract</b>	<b>2</b>
<b>2</b>	<b>Adatmenedzsment es leiro statisztikak</b>	<b>2</b>
2.1	Package-ek betoltese . . . . .	2
2.2	Sajat funkcio . . . . .	2
2.3	A Bully-zas adat betoltese . . . . .	2
2.4	Adatellenorzes es adattisztitas . . . . .	3
<b>3</b>	<b>A kevert modellek alapfogalmai</b>	<b>3</b>
3.1	Clustering (csoportosulas) feltarasa . . . . .	3
3.2	Kevert modellek . . . . .	4
3.3	A random hatasok ket tipusa . . . . .	5
3.4	Annak eldontese hogy random slope vagy random intercept modell-t illesszunk . . . . .	9
3.5	Mit kell kozolni az elemzesrol . . . . .	11

# 1 Absztract

Ebben a gyakorlatban megismerheted a kevert modellekkel kapcsolatos alapfogalmakat, valamint hogy hogyan lehet oket felepiteni.

## 2 Adatmenedzsment es leiro statisztikak

### 2.1 Package-ek betoltese

Ebben a gyakorlatban a kovetkezo package-ekre leszsz szukseg:

```
library(psych) # for describe
library(tidyverse) # for tidy code and ggplot2
library(cAIC4) # for cAIC
library(r2glmm) # for r2beta
library(lme4) # for lmer
library(lmerTest) # to get singificance test in lmer
```

### 2.2 Saját funkció

Ezzel a funkcióval kinyerhetjük a standardizált Beta együtthatót a kevert modellekből. Ez a funkció innen lett atemelve: <https://stackoverflow.com/questions/25142901/standardized-coefficients-for-lmer-model>

```
stdCoef.merMod <- function(object) {
  sdy <- sd(getME(object, "y"))
  sdx <- apply(getME(object, "X"), 2, sd)
  sc <- fixef(object) * sdx/sdy
  se.fixef <- coef(summary(object))[, "Std. Error"]
  se <- se.fixef * sdx/sdy
  return(data.frame(stdcoef = sc, stdse = se))
}
```

### 2.3 A Bully-zas adat betoltese

Ebben a gyakorlatban az altalanos iskolai bully-zasrol (magyarul talan “zaklatas”?) teszunk fel kutatasi kerdeseket. Ez egy szimulalt adatbazis, vagyis nem valodi adatokat tartalmaz, de kepzeld el, hogy az adatok a kovetkezo kutatashoz szarnazank: Ebben a kutatashoz az erdekel minket, hogy a testsuly hogyan beoflyasolja a gyerekek serulekenyseget a bully-zassal szemben. A kutatok azt feltetelezik hogy a testsuly osszefugg az elvett szendvicsek szamaval.

Valtozok:

- sandwich\_taken - A bullyzassal kapcsolatos serulekenyseget meroszama. A kutatashoz megkerdeztuk a vizgaltai szemelyeket (altalanos iskolai gyerekek) hogy az elmult honapban hanyszor kenyyszeritettek ki toluk a bully-k az ebekre hozott szendvicsuket
- weight - testsuly
- class - faktor valtozo ami azt mutatja melyik iskolai osztalyba jar a vizsgalati szemely. Faktorszintek: class\_1, class\_2, class\_3, class\_4.

Ket adatfajlt is betoltunk. Mindket adafajlt ugy lett legeneralva, hogy a diakok kulonboznak abban, hogy mennyi szendvicset vesznek el toluk attol fuggoen hogy milyen a testsulyuk es attol fuggoen is hogy melyik osztalyba jarnak. Vagyis mind a testsulynak, mind az osztalynak van hatas az elvett szendvicsek szamara. Viszont a ket adatbazis kulonbozik abban, hogy az, hogy a diak melyik osztalyba jar, beoflyasolja-e hogy a testsulynak mekkora hatasa van az elvett szendvicsek szamara. A data\_bully\_int.csv adatfajlban a testsuly hatasa ugyan akkora minden osztalyban (fuggetlen az osztalytol), mig a data\_bully\_slope.csv adatfajlban a testsuly hatasa kulonbozik osztalyonkent.

```
# load data
data_bully_int = read.csv("https://raw.githubusercontent.com/kekecsz/PSYP13_Data_analysis_class-2018/main/data_bully_int.csv")

# assign class as a grouping factor
data_bully_int$class = factor(data_bully_int$class)

data_bully_slope = read.csv("https://raw.githubusercontent.com/kekecsz/PSYP13_Data_analysis_class-2018/main/data_bully_slope.csv")
data_bully_slope$class = factor(data_bully_slope$class)
```

## 2.4 Adatellenorzes es adattisztitas


Ahogy mindig, eloszor kezdj az adatok ellenorzesével es az esetleges adattisztitással. Ehhez használhatod a View(), summary(), es describe() funkeioakat, es a ggplot() funkeiot vizualizalashoz.

## 3 A kevert modellek alapfogalmai

### 3.1 Clustering (csoportosulas) feltarasa

Vizualizaljuk a sandwich\_taken es weight valtozok osszefuggeset egy pontdiagram (scatterplot) segítségével. Az adatok egy egyértelmű negatív összefüggést mutatnak a sandwich\_taken es weight valtozok között, de az adatok variabilitása nagyon nagy.

```
data_bully_int %>% ggplot() + aes(y = sandwich_taken, x = weight) +
  geom_point(aes(color = class), size = 4) + geom_smooth(method = "lm",
  se = F)
```




A `pon_tok` színe az ábrán azt mutatja, a diák melyik iskolai osztályba jár (`class_1`, `class_2`, `class_3`, vagy `class_4`). Ha jobban megnezzük, úgy tűnik, hogy az azonos színű pontok egymáshoz közel helyezkednek el az ábrán, nem pedig random módon elszórva, ami arra utal, hogy az adatpontok nem teljesen függetlenek egymástól, hanem csoportosulnak (clustereződnek).

Nezzük meg, hogy az iskolai osztály meg tudja-e magyarázni a variabilitás egy részét. Például felrajzolhatjuk a regressziós egyeneseket csoportonként. Ez úgy tűnik, hogy megmagyarázza a variabilitás egy részét, hiszen a regressziós vonalak közelebb kerülnek a valós megfigyelésekhez. Szóval úgy tűnik, hogy érdemes lenne a `class` változót is figyelembe venni a modellünk megépítésénél.

(Alább az ábrát elmentjük egy `int_plot` nevű objektumba, hogy később ugyan ezt az ábrát könnyen előhívhassuk.)

```
int_plot = data_bully_int %>% ggplot() + aes(y = sandwich_taken,
  x = weight, color = class) + geom_point(size = 4) + geom_smooth(method = "lm",
  se = F, fullrange = TRUE)
```

`int_plot`



### 3.2 Kevert modellek

Jelen kutatásban csak az érdekel minket, hogy a testsúly befolyásolja-e az elvett szendvicsek számát, és ha igen, mennyire. Az iskolai osztályok hatása nem fontos a kutatás alapkerdesére szempontjából, és még ha az is lenne, az információt amit ezekről az iskolai osztályokról szerzünk nem tudnánk általánosítani más iskolákban, hiszen a többi iskolában más osztályok vannak, amiknek vélhetően mások a karakterisztikái. Szóval az iskolai osztály ebben az esetben egy “zavaró tényező” (nuisance variable). Vagyis ezt a `class` változót nem szeretnénk figyelembe venni a regressziós egyeletben, hiszen akkor más iskolákban nem tudnánk felhasználni az egyeletet.

A kevert modellek segítségével figyelembe vehetjük az adatok ilyen fajta csoportosulását anélkül, hogy a regressziós egyenletünkbe be kellene tennünk ezeket a zavaró tényezőket.

Itt fontos megkülönböztetnünk a hatások két típusát.

**Fix hatások (Fixed effects)** - Azokat a hatásokat amikkel eddig a lineáris modellekben foglalkoztunk, “fix hatásoknak” (fixed effects) nevezzük. Ezek azok a hatások/prediktorok, amikre regressziós együtthatókat számítottunk ki. Ezek a predikciós modellünk részei, amiket a későbbiekben is felhasználunk majd a bejósoláshoz.

**Random hatások (Random effects)** - Azokat a hatásokat, amiket a “zavaró tényezőknek” tulajdonítunk, modellezhetjük random hatásként. A random hatásokat úgy képzeljük el, hogy bár a megfigyelések különböznek a csoportosulások mentén, de az egyes csoportok (mint például itt az osztályok) hatása nem szisztematikus, hanem egyfajta véletlenszerű különbségből fakad a csoportok között. A csoportok közötti ilyen véletlenszerű különbség felismerése segít abban, hogy pontosabban megbecsüljük a fix hatások mértékét és azokkal kapcsolatos bizonyosságunkat. Ezek a random hatások nem kerülnek bele a regressziós egyenletünkbe, és nem kapunk velük kapcsolatban regressziós együtthatókat.


Ezért azokat a modelleket, amik mind fix, mind random hatásokat tartalmaznak, kevert modelleknek (mixed models) nevezzük.

### 3.3 A random hatások két típusa

Általánosságban a random hatások két módon lehetnek hatással a kimeneti változóra. Az egyik hogy közvetlenül fejtenek ki rá (random intercept), a másik hogy arra vannak hatással, hogy a fix hatások mértékét és irányát befolyásolják (random slope).

**random intercept, random slope nélkül:** Lehetséges hogy a csoportosulások (cluster-ek) csak abban különböznek egymástól, hogy a kimeneti változon átlagosan milyen értéket vesznek fel, de a fix hatások nagyjából azonosak a csoportosulások között. Ez igaz a `data_bully_int` adatbázisra. Megfigyelhetjük az ábrán, hogy a regressziós egyenesek meredeksége (slope) nem különbözik az osztályok között, ami arra utal, hogy a testsúly hatása ugyanakkora az egyes osztályokban. Az osztályok csak abban különböznek, hogy milyen “magasan” vannak a regressziós egyenesek, vagyis abban, hogy a regressziós egyenesek milyen értéket vesznek az Y tengelytől. Ez látható az alábbi ábrán is.

```
int_plot + xlim(-1, 50) + geom_hline(yintercept = 0) + geom_vline(xintercept = 0)
```



**random intercept, es random slope:** Most vizsgáljuk meg a másik adatbázist (`data_bully_slope`). Ahogy fent említettük, ebben az adatbázisban azt szimuláltuk, hogy az osztálynak nem csak az elvett szendvicsek számára van hatása, hanem a testsúly hatása is különbözik az osztályok között.


Az ábrán jól látszik, az osztályok nem csak abban különböznek, hogy a hozzájuk tartozó regressziós egyenes hol metszi az Y tengelyt, de a regressziós egyenesek meredeksége is különbözik.

Peldaul a `class_1`-ben a testsúly hatása elhanyagolhatónak tűnik abból a szempontból hogy kitől mennyi szendvicset vesznek el, míg a `class_2`-ben és `class_4`-ben a testsúly hatása számottevő.

```
slope_plot = data_bully_slope %>% ggplot() + aes(y = sandwich_taken,
  x = weight, color = class) + geom_point(size = 4) + geom_smooth(method = "lm",
  se = F, fullrange = TRUE) + xlim(-1, 50) + geom_hline(yintercept = 0) +
  geom_vline(xintercept = 0)
slope_plot
```

```
## Warning: Removed 1 rows containing non-finite values (stat_smooth).
```

```
## Warning: Removed 1 rows containing missing values (geom_point).
```



Az alábbi feladat bemutatja, hogy hogyan lehet a random hatásokat beépíteni a modellekbe.

Harom modellt fogunk építeni. Eloszor egy szimpla fix hatásokat tartalmazó modellt, majd egy **random intercept modellt**, és egy **random slope modellt**. A fenti ábra alapján arra lehet következtetni hogy az iskolai osztály egy olyan random hatás, ami mind a regressziós egyenes intercept-jét, mind a meredkséget (slope) befolyasolja a `data_bully_slope` adatbázisban. Ezért normalis esetben csak a random slope modellt illesztünk. A többi modell csak demonstrációs célból építjük, hogy összehasonlítsuk azok formulait és bejósoló erejét a random slope modellel.

Eloszor építünk egy egyszerű regressziós modellt, melyben egyetlen fix hatás prediktor van: `weight`. Ezt a modellt a `mod_fixed` objektumba mnetjük.

**egyszerű regressziós model** (csak fix hatás)

```
mod_fixed = lm(sandwich_taken ~ weight, data = data_bully_slope)
```

**random intercept modell** (a random intercept megengedett, de a random slope nem)

A kevert modellek formulája nagyon hasonló a csak fix hatást tartalmazó modellekehez, de az `lm()` funccio helyett az `lmer()` funkciót használjuk.

A random intercept random hatást a “+ (1|class)” hozzáadásával tehetjük a modellbe.

Ez gyakorlatilag azt jelenti, hogy megengedjük a modellnek hogy külön regressziós egyenest illesszen minden clusterre (a mi esetünkben minden iskolai osztályra), de azt meghatározzuk, hogy minden regressziós egyenesnek ugyan olyan legyen a meredeksége.

Ezt normalis esetben akkor tennénk, ha azt gyanítanánk hogy az osztályok között nincs lényegi eltérés a fix hatásokban, csak a kimeneti változó átlagos szintjében. Ez a modell jól illeszkedne a `data_bully_int` adatbázisra, de a fenti ábra alapján azt várjuk hogy a `data_bully_slope` adatbázisra kevesbe jól illeszkedik

majd.

```
mod_rnd_int = lmer(sandwich_taken ~ weight + (1 | class), data = data_bully_slope)
```

**random slope modell** (mind a random intercept, mind a random slope megengedett):

Ennek a modelnek a formulaja szinte teljesen megegyezik a random intercept modellel, egyedül abban különbözik, hogy a random hatásról szóló részben “+ (1|class)” helyett “+ (weight|class)” szerepel. Ez arra utal, hogy a class random hatás nem csak az interceptre, hanem a weight prediktor hatására is kiterjed.

Ezzel megengedjük a modellünknek, hogy külön regressziós egyenest illesszen minden clusterre, és hogy azoknak mind az Y tengellyel való metszéspontja (intercept), mind a meredeksége (slope) különbözhet.

```
mod_rnd_slope = lmer(sandwich_taken ~ weight + (weight | class),  
  data = data_bully_slope)
```

```
## Warning in checkConv(attr(opt, "derivs"), opt$par, ctrl =  
## control$checkConv, : Model failed to converge with max|grad| = 0.00317298  
## (tol = 0.002, component 1)
```

Ha összehasonlítjuk a három modell rezidualis hibáját (residual sum of squares differences - RSS), láthatjuk, hogy a csak fixed hatást tartalmazó modell használatakor marad a legtöbb hiba, a random intercept modell a második, és a legkevesebb hibát a random slope modell esetén találjuk.

```
sum(residuals(mod_fixed)^2)
```

```
## [1] 581.6364
```

```
sum(residuals(mod_rnd_int)^2)
```

```
## [1] 159.5818
```

```
sum(residuals(mod_rnd_slope)^2)
```

```
## [1] 132.2322
```

De ez nem igazán meglepő, hiszen a modell komplexitása (és ezzel flexibilitása) egyre nőtt, és erről tudjuk, hogy csökkenti a hibát azon az adatbázison, amin a modellt építettük, de a flexibilitás növelese miatt ez túlillesztéshez is vezethet, ami új adatokon rosszabb bejelölési hatékonysághoz is vezethet. Ezért a nyers rezidualis hiba összehasonlítás helyett olyan modell-illeszkedési mutatókhoz kell fordulnunk, amelyek korrigálva vannak a flexibilitására (ezt úgy is mondhatjuk, hogy a modell paraméterek számára.)

Az egyik ilyen mutató az AIC. De a kevert modellekhez egy speciális AIC mutatót számítottunk ki, a cAIC mutatót (ami a conditional AIC-ből származik). A cAIC-t megkaphatjuk például a cAIC4 csomag cAIC() függvénye segítségével.

```
AIC(mod_fixed)
```

```
## [1] 391.7357
```

```
cAIC(mod_rnd_int)$caic
```

```
## [1] 294.4023
```

```
cAIC(mod_rnd_slope)$caic
```

```
## [1] 285.6445
```



### 3.4 Annak eldöntése hogy random slope vagy random intercept modell-t illesszünk

Ahogy korábban is láthattuk, a modellválasztásnál mindig az elméletileg leginkább megalapozott modellt érdemes választani. Ha van okunk feltételezni hogy egy hatás különböző lesz a különböző csoportokban, akkor használjuk a random slope modellt. Ha elméleti alapon inkább úgy itéljük, hogy a fix hatások valószínűleg állandóak a csoportok között, illesszünk random intercept modellt.

Ennek ellenére van olyan eset, amikor elméletileg mindkét eshetőség elképzelhető. Ilyen esetben hagyatkozhatunk az exploratoros elemzésünkre és a modellilleszkedési mutatókra, hogy eldöntsük, melyik modellt érdemesebb használni.

#### 3.4.1 Random hatások vizualizációja

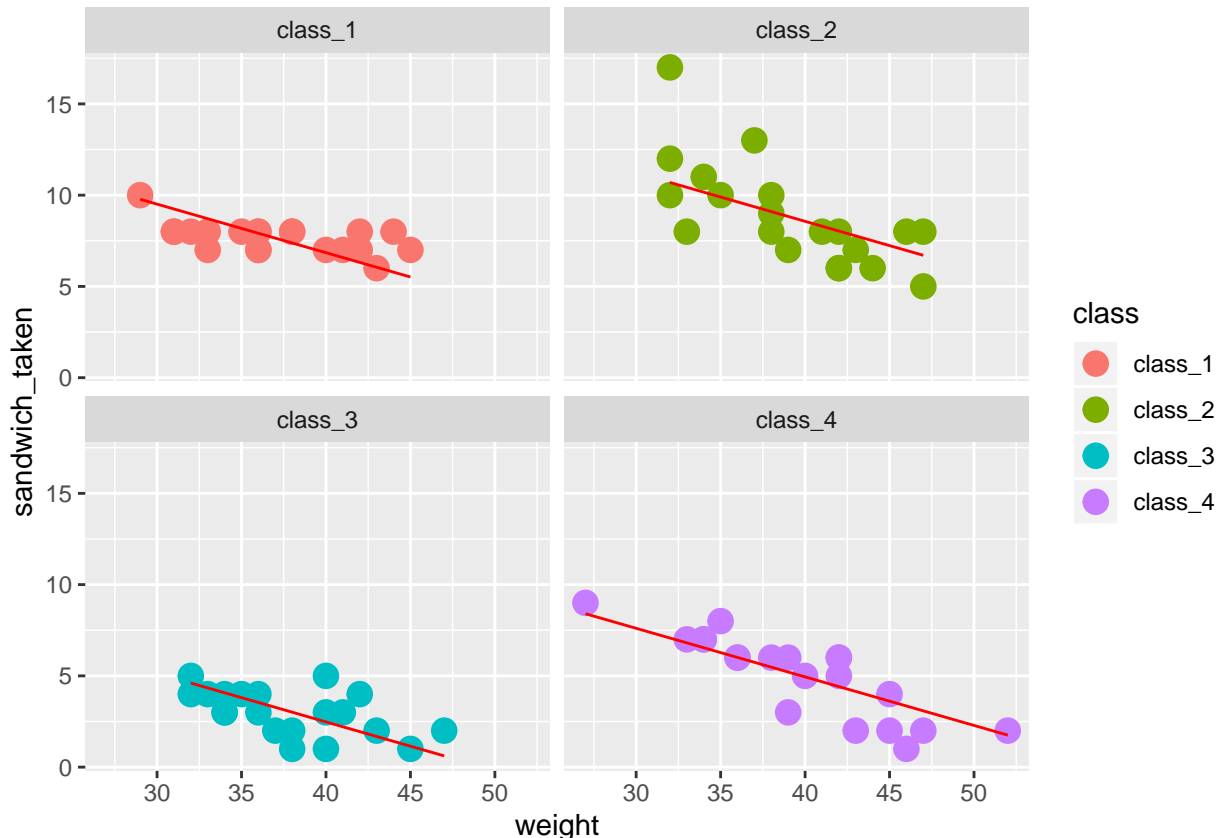
A random hatások explorációja esetén a vizualizáció kulcsszerepet tölt be.

Eloszor érdemes elmentenünk az intercept és a slope modellek által bejósolt értékeket új változókba (alább a `pred_int` és `pred_slope` változókba mentjük ezeket). Az eredeti adatbázisból származó predikciókat a `predict()` funkcióval nyerhetjük ki.

```
data_bully_slope = data_bully_slope %>% mutate(pred_int = predict(mod_rnd_int),  
  pred_slope = predict(mod_rnd_slope))
```

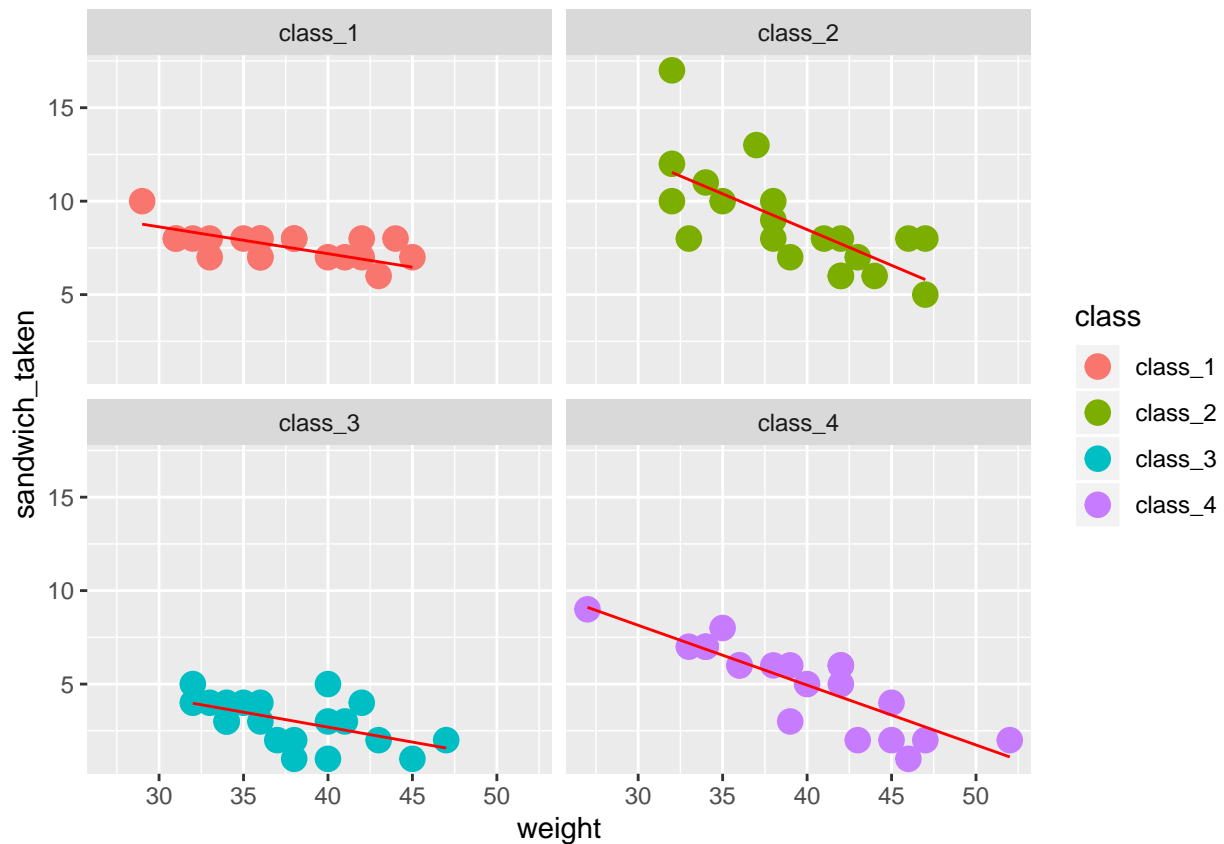
Igy vizualizáljuk a random intercept modell predikcióit:

```
data_bully_slope %>% ggplot() + aes(y = sandwich_taken, x = weight,  
  group = class) + geom_point(aes(color = class), size = 4) +  
  geom_line(color = "red", aes(y = pred_int, x = weight)) +  
  facet_wrap(~class, ncol = 2)
```



Igy pedig a random slope modell predikciojat:

```
data_bully_slope %>% ggplot() + aes(y = sandwich_taken, x = weight,  
  group = class) + geom_point(aes(color = class), size = 4) +  
  geom_line(color = "red", aes(y = pred_slope, x = weight)) +  
  facet_wrap(~class, ncol = 2)
```



Az abrak összehasonlítása alapján bár a random slope modell valamelyest jobb illeszkedéshez vezet, a különbség alig észrevehető.

### 3.4.2 Modell-illeszkedési mutatók használata

A modellek illeszkedését a cAIC segítségével is összehasonlíthatjuk. Ahogy korábban is láttuk az AIC esetén, ha az egyik modell cAIC mutatója legalább 2-vel alacsonyabb mint a másik modellhez tartozó cAIC, akkor azt mondhatjuk az alacsonyabb cAIC mutatóval bíró modell szignifikánsan jobban illeszkedik az adatokhoz. Az anova() funkció szintén használható a modellek összehasonlítására, de itt is csak a begyazott modellek esetén (lásd a modell-összehasonlítás gyakorlatot).

(Az anova() funkció használatkor egy figyelmeztetést kapunk: 'refitting model(s) with ML (instead of REML)' ez természetes és figyelmen kívül hagyható, a REML és az ML módszerrel illesztett modellek nagyon hasonlóak)

```
cAIC(mod_rnd_int)$caic
```

```
## [1] 294.4023
```

```
cAIC(mod_rnd_slope)$caic
```

```
## [1] 285.6445
```

```
anova(mod_rnd_int, mod_rnd_slope)

## refitting model(s) with ML (instead of REML)
## Data: data_bully_slope
## Models:
## mod_rnd_int: sandwich_taken ~ weight + (1 | class)
## mod_rnd_slope: sandwich_taken ~ weight + (weight | class)
##           Df      AIC      BIC logLik deviance  Chisq Chi Df Pr(>Chisq)
## mod_rnd_int    4 310.00 319.53 -151.00   302.00
## mod_rnd_slope    6 307.94 322.23 -147.97   295.94 6.0595      2    0.04833 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

### 3.5 Mit kell kozolni az elemzesrol

A kozlendo informaciok nagyopn hasonloak ahhoz, amit a fix hatas modellek eseten kozoltunk.

Eloszor is le kell irnunk a modszert amit hasznaltunk:

“Ahhoz hogy a bullyzassal szembeni serulekenyseget meghatarozzuk, egy kevert linearis modellt illesztettunk. A kevert modellben az elvett szendvicsek szamat a testsullyal mint fix hatasu prediktorral josoltuk be. A modellben ezen felul az iskolai osztaly random hatasat modelleztuk. Epitettunk mind egy random slope es egy random intercept modellt. Ahogy ezt a kutatasi tervunkben meghataroztuk, a ket modellt osszehasonlitottuk a cAIC modellilleszkedeis mutatojuk alapjan, es ez alapjan hataroztuk meg, melyik lesz a vegso bejoslo modellunk.”

A kovetkezo funktiokkal kapnank meg a kutatasi jelenteshoz szukseges eredmenyeket:

cAIC:

```
cAIC(mod_rnd_int)$caic
```

```
## [1] 294.4023
```

```
cAIC(mod_rnd_slope)$caic
```

```
## [1] 285.6445
```

anova:

```
anova(mod_rnd_int, mod_rnd_slope)

## refitting model(s) with ML (instead of REML)
## Data: data_bully_slope
## Models:
## mod_rnd_int: sandwich_taken ~ weight + (1 | class)
## mod_rnd_slope: sandwich_taken ~ weight + (weight | class)
##           Df      AIC      BIC logLik deviance  Chisq Chi Df Pr(>Chisq)
## mod_rnd_int    4 310.00 319.53 -151.00   302.00
## mod_rnd_slope    6 307.94 322.23 -147.97   295.94 6.0595      2    0.04833 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Modell  $R^2$  es regressziós egytutthatok:

Az `r2beta()` funktio kiszamitja a “marginalis  $R^2$ ” mutatot Nakagawa es Schielzeth (2013) cikkének ajajnlasa alapjan. Ez az  $R^2$  mutato specialis fajtaja, ami azt mutatja meg, hogy mekkora a modell fix hatasu prediktorai által megmagyarazott varianciaarany. Ezt az  $R^2$  mutatot erdemes hasznalni a modell bejoslo

hatekonysaganak megadasara, hiszen a random hatasu prediktorokat uj adatokon nem tudjuk majd hasznalni bejoslasra.

Nincs egy klasszikus F-test aminek az eredmenyet fel lehetne hasznalni annak ertekelesere, hogy a teljes modell szignifikansan jobb bejoslast eredményez-e a null-modellnel, de az `r2beta` megadja a 95%-s konfidencia intervallumot, amit felhasználhatunk szignifikanciatesztesre. Ahogy korabban is, ha a konfidencia intervallim tartalmazza a 0-t, akkor a modell nem szignifikansan kulonbozik a null modelltol bejoslo hatekonysag tekinteteben.

Reference: Nakagawa, S., & Schielzeth, H. (2013). A general and simple method for obtaining R2 from generalized linear mixed-effects models. *Methods in Ecology and Evolution*, 4(2), 133-142. and Johnson, P. C. (2014). Extension of Nakagawa & Schielzeth's R2GLMM to random slopes models. *Methods in Ecology and Evolution*, 5(9), 944-946.

```
r2beta(mod_rnd_slope, method = "nsj", data = data_bully_slope)
```

```
## Effect Rsq upper.CL lower.CL
## 1 Model 0.147 0.304 0.036
## 2 weight 0.147 0.304 0.036
```

Az eredmények resyben így írhatjuk le az eredményeket:

“A random slope modell jobb modell-illezkedeshez vezetett mint a random intercept modell mind a likelihood ration test ( $\chi^2 = 6.06$ ,  $df = 2$ ,  $p = .048$ ) mind a cAIC alapján (cAIC intercept = 294.4, cAIC slope = 285.64). Ezért az alábbiakban a random slope modell eredményeit közöljük.

A kevert lineáris modell szignifikansan jobb volt mint a null modell. A modellben a fix hatasu prediktorok az elvett szendvicsek varianciajanak 14.71%-at magyaráztak meg ( $R^2 = 0.15$  [95% CI = 0.04, 0.3]).

Ezen felül a prediktorokhoz tartozó regressziós együtthatókról is közölnünk kell az eredményeket. Ezt a korábbiakhoz hasonlóan egy táblázatban szoktuk megtenni, ami minden prediktorra külön sorban közli az adatokat. (Itt csak egy fix hatasu prediktor van, szóval csak két sor lesz a táblázatban, egy az intercept-nek és egy a testsúly prediktornak.)

A végső táblázat valahogy így néz majd ki:

```
##           b 95%CI lb 95%CI ub Std.Beta p-value
## (Intercept) 15.89      8.02  23.72      0    .021
## weight      -0.25     -0.41  -0.09     -0.42    .04
```

A táblázat egyes elemeit itt találhatod meg:

Regressziós együtthatók és a hozzájuk tartozó p-értékek a `summary()` függvénnyel kaphatók meg (csak akkor fog p-értéket kiadni a `summary` függvény a kevert modellekre, ha az `lmerTest` package be van töltve)

```
summary(mod_rnd_slope)
```

```
## Linear mixed model fit by REML. t-tests use Satterthwaite's method [
## lmerModLmerTest]
## Formula: sandwich_taken ~ weight + (weight | class)
## Data: data_bully_slope
##
## REML criterion at convergence: 297.4
##
## Scaled residuals:
##      Min       1Q   Median       3Q      Max
## -2.3403 -0.5630 -0.0076  0.3896  4.0511
##
## Random effects:
## Groups   Name                Variance Std.Dev. Corr
```

```
## class      (Intercept) 44.61736 6.6796
##           weight      0.01693 0.1301   -0.94
## Residual              1.81799 1.3483
## Number of obs: 80, groups:  class, 4
##
## Fixed effects:
##           Estimate Std. Error      df t value Pr(>|t|)
## (Intercept) 15.88887   3.55290   2.95835   4.472   0.0215 *
## weight      -0.25155   0.07224   2.98048  -3.482   0.0404 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Correlation of Fixed Effects:
##      (Intr)
## weight -0.940
## convergence code: 0
## Model failed to converge with max|grad| = 0.00317298 (tol = 0.002, component 1)
```

A regressziós egyutthatokhoz tartozó konfidencia intervallumok: (ez a funkció sokaig fut, mert sok iterációt vegez a kiszámításhoz)

```
confint(mod_rnd_slope)
```

A standardizált beta értékeket pedig a `stdCoef.merMod()` saját funkcióval lehet kinyerni:

```
stdCoef.merMod(mod_rnd_slope)
```

```
##           stdcoef      stdse
## (Intercept) 0.000000 0.0000000
## weight      -0.422144 0.1212255
```